Journal of The Institute of Electronics and Information Engineers Vol.62, NO.10, October 2025 https://doi.org/10.5573/ieie.2025.62.10.76
ISSN 2287-5026(Print) / ISSN 2288-159X(Online)

논문 2025-62-10-10

EBM-LSTM 하이브리드 모델을 활용한 항공기 터빈 엔진 잔여 수명 예측

(Predicting Remaining Life of Aircraft Turbine Engines using EBM-LSTM Hybrid Models)

김 기 현*, 김 주 현**, 임 대 영*, 권 종 원*

(Kihyun Kim, Juhyun Kim, Daeyeong Lim, and Jongwon Kwon©)

요 약

본 논문은 항공기 터빈 엔진의 잔여 수명(RUL) 예측에서 해석 가능성과 예측 정확도를 동시에 향상시키기 위해, 설명가능한 인공지능(XAI) 모델인 EBM(Explainable Boosting Machine)과 시계열 예측 모델인 LSTM(Long Short Term Memory)을 결합한 EBM-LSTM 하이브리드 방법론을 제안한다. 제안된 방법론은 EBM 모델이 제공하는 변수 중요도를 활용하여 고차원의 센서 데이터로부터 잔여 수명 예측에 중요한 영향을 미치는 변수를 선택하여 LSTM 모델의 입력으로 활용한다. 이 과정을 통해 변수 선택의 투명성을 확보하고 불필요한 변수를 제거하여 모델의 복잡도와 학습 비용을 절감한다. 제안된 방법론의 유효성을 검증하기 위해 NASA의 C-MAPSS 데이터셋을 활용하였으며, EBM-LSTM 하이브리드 모델의 성능을 단일 EBM, LSTM 모델 및 딥러닝을 활용한 사전 연구와 비교 분석하였다. 실험 결과 변수 선택 과정을 통해 입력 변수를 14개에서 8개로 차원 축소를 수행한 결과, 결정계수(R^2)의 성능 저하는 0.46%에 불과하여 모델의 예측 성능을 유지하며 효율성과 강건성을 입증하였다. 제안된 EBM-LSTM 하이브리드 방법론은 잔여 수명 예측 모델의 신뢰도를 높여, 고신뢰성이 요구되는 항공우주 및 다양한 산업 분야에서 인공지능 기반 예지보전 시스템의 현장 적용 가능성을 높이는 데 기여할 것으로 기대된다.

Abstract

This paper proposes an EBM-LSTM hybrid methodology that combines the Explainable Boosting Machine (EBM), an explainable artificial intelligence (XAI) model, with the Long Short Term Memory (LSTM), a time series prediction model, to simultaneously improve interpretability and prediction accuracy in aircraft turbine engine Remaining Useful Life (RUL) prediction. The proposed methodology utilizes the variable importance provided by EBM to select variables that significantly influence RUL prediction from high-dimensional sensor data, which are then used as inputs for the LSTM model. This process ensures transparency in variable selection while reducing model complexity and training costs by eliminating unnecessary variables. To validate the effectiveness of the proposed methodology, NASA's C-MAPSS dataset was utilized, and the performance of the EBM-LSTM hybrid model was compared and analyzed against individual EBM and LSTM models as well as previous studies using deep learning approaches. Experimental results showed that through the variable selection process, dimensionality reduction from 14 to 8 input variables resulted in only a 0.46% decrease in coefficient of determination (R^2) performance, maintaining the model's prediction performance while demonstrating efficiency and robustness. The proposed EBM-LSTM hybrid methodology is expected to contribute to enhancing the field applicability of AI-based predictive maintenance systems in aerospace and various industrial sectors requiring high reliability by improving the reliability of RUL prediction models.

Keywords : Remaining useful life, Explainable artificial intelligence, Feature selection, Ensemble techniques

*정회원, **비회원, 한국산업기술시험원 산업인공지능혁신센터(Industrial AI Innovation Center, Korea Testing Laboratory)
© Corresponding Author(E-mail : kjw79@ktl.re.kr)
※ This work was supported by the Korea Institute for Advancement of Technology(KIAT) grant funded by the Ministry of Trade, Industry and Energy(MOTIE)(No. P0022671, Basis for Implementing Industrial Digital Transformation Conformity Assessment and Testbed Platform).
Received ; July 29, 2025 Revised ; August 28, 2025 Accepted ; September 8, 2025

Copyright © The Institute of Electronics and Information Engineers.

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (http://creativecommons.org/licenses/by-nc/3.0) which permits unrestricted non-commercial use, distribution and reproduction in any medium, provided the original work is properly cited.

Ⅰ. 서 론

최근 인공지능 기술의 발전은 설비의 신뢰성 확보와 운영 효율 향상을 위한 예지보전(Prognostics and Health Management, PHM) 분야에 새로운 패러다임을 제시하였다. 특히, IoT 센서를 통해 수집된 방대한 데이터를 기반으로 설비의 잔여 수명(Remaining Useful Life, RUL)을 정밀하게 예측하는 연구가 항공우주, 배터리 등 다양한 산업에서 활발히 진행되었다[1, 2]. 잔여 수명 예측의 정확성은 설비의 우발적 고장을 방지하고 상태기반정비(Condition-Based Maintenance, CBM)의 효율을 극대화하여, 결과적으로 높은 유지보수 비용을 절감하는 데 직접적인 영향을 미치고 있다[3].

기존 잔여 수명 예측 연구는 주로 예측 정확도 향상을 목표로 딥러닝 기반의 모델 개발에 집중되어 왔다[4]. 그러나 이러한 모델들은 복잡한 내부 구조로 인해 예측 결과의 원인을 파악하거나 정량적으로 해석하기 어려운 '블랙박스(Black-box)'라는 본질적 한계를 가진다[5]. 항공기 터빈 엔진과 같이 안전이 최우선시되는 고신뢰성 시스템에서는 단순히 높은 예측 정확도를 넘어, 예측 결과의 근거를 명확히 이해하고 의사결정의 신뢰도를 높이는 것이 매우 중요하다[6]. 이러한 블랙박스의 한계를 극복하기 위해, 예측 결과를 사후적으로 해석하는 Post-hoc 방식의 연구가 시도되었으나, 이는 모델의 실제 동작 방식을 근사적으로 추정하는 것이므로 해석의 정확성을 보장하기 어렵다는 한계가 있다.

본 연구에서는 이러한 문제를 근본적으로 해결하기 위해, 모델 자체가 설명력을 내재한 Ante-hoc 접근법을 변수 선택 단계에 적용하고, 이를 하이브리드 예측 모델과 결합하는 새로운 방법론을 제안한다. 항공기 터빈 엔진에 부착된 다수의 센서로부터 수집되는 고차원의 시계열 데이터는 복잡한 열화 과정을 반영하지만, 모든 센서가 잔여 수명 예측에 유의미한 정보를 제공하는 것은 아니다. 불필요한 변수를 모두 학습에 사용할 경우 과적합이나 연산 비용 증가로 예측 모델의 성능과 효율성이 저하될 수 있다. 따라서 본 연구에서는 모델 자체가 우수한 설명력을 제공하는 EBM(Explainable Boosting Machine) 모델을 활용하여 잔여 수명 예측에 영향을 미치는 핵심 변수를 체계적으로 선별한다. 대부분의 신경망, 부스팅 계열 모델이 낮은 설명력을 갖는 반면, EBM은 높은 예측 정확도를 유지하면서도 뛰어난 설명력을 제공하여 본 연구의 목적에 가장 적합한 모델로 판단하였다. EBM 모델은 ISO/IEC TR 24028 표준에서 분류하는 모델링단계의 설명가능성, 즉 Ante-hoc 접근법에 해당한다[7]. 이는 복잡한 블랙박스 모델의 결과를 사후에 추정하는 Post-hoc 방식과 달리, 모델 자체가 내부 구조에 대한 명확한 해석을 제공하여 예측 결과에 대한 근본적인 신뢰를 구축한다. 이러한 내재된 투명성은 규제 준수와 같이 AI 모델의 결정 근거를 명확히 제시해야 하는 실용적 관점에서 특히 유리하다. EBM을 통해 도출된 변수별 기여도를 기반으로 핵심 센서 변수들을 선별하고, 이를 시계열 예측에 특화된 LSTM(Long Short Term Memory) 모델의 입력으로 활용하는 하이브리드 방법론을 구축하였다. 제안된 방법론은 EBM을 통해 변수 선택 과정의 객관적 근거를 마련하며, 정제된 데이터를 기반으로 LSTM 모델의 예측 성능과 학습 효율성을 동시에 향상시키는 효과를 보여준다.

본 연구의 기여점은 다음과 같다. 첫째, 잔여 수명 예측의 정확도와 설명 가능성 간 Trade-off를 해결하기 위해, 내재적 설명력(ante-hoc)을 갖는 EBM 모델을 변수 선택에 활용하고 이를 시계열 모델인 LSTM과 결합한 새로운 하이브리드 방법론을 제시한다. 둘째, EBM 모델이 제공하는 변수별 전역 중요도를 활용하여 성능 저하를 최소화하면서 입력 변수를 체계적으로 축소할 수 있음을 실험을 통해 나타내고, 이를 통해 모델의 연산 효율성과 강건성을 향상시켰다. 셋째, 높은 성능의 블랙박스 모델을 제시하는 데 그치지 않고, 예측 근거를 내재적으로 명확히 하여 최종 사용자인 엔지니어가 그 결과를 신뢰하고 실제 유지보수 의사결정에 적용할 수 있는 실용적 방법론의 토대를 마련하였다.

본 논문의 구성은 Ⅱ장에서는 관련 이론인 EBM 모델 및 잔여 수명 예측에 적용된 기존 방법론들을 소개하고, Ⅲ장에서는 제안하는 하이브리드 방법론의 구조를 서술한다. Ⅳ장에서는 실험 설계 및 결과를 통해 제안 모델의 성능을 입증하며, Ⅴ장에서는 결론 및 향후 연구 과제를 제시한다.

Ⅱ. 관련 문헌 연구

항공기 터빈 엔진의 잔여 수명 예측 연구는 크게 모델 기반, 데이터 기반, 그리고 이 둘을 결합한 하이브리드 방법으로 구분할 수 있다[8]. 모델 기반 방법은 시스템의 물리적, 수학적 모델을 통해 열화 과정을 설명하지만, 복잡한 항공기 터빈 엔진 시스템에 적용하기에는 많은 사전 지식과 가정이 요구되는 한계가 있다[9]. 반

면, 데이터 기반 방법은 IoT 기술 발전으로 풍부해진 센서 모니터링 데이터에 주로 의존하며, 시스템에 대한 깊은 이해 없이도 복잡한 패턴을 학습할 수 있어 최근 잔여 수명 예측 연구가 활발히 수행되고 있다[1].

데이터 기반 방법론 중에서도 특히 딥러닝 모델은 잔여 수명 예측에서 뛰어난 성능을 보이며 활발한 연구가 진행되고 있다[10]. 가장 대표적인 접근법은 다변량 시계열 데이터의 공간적 특징과 시간적 의존성을 동시에 학습하는 하이브리드 모델이다[11]. 이 구조에서 CNN은 센서 데이터 간의 공간적 패턴을 추출하며, LSTM 또는 간소화된 구조인 GRU(Gated Recurrent Unit)를 통해 시간에 따른 항공기 터빈 엔진의 동적 열화 과정을 모델링하는 역할을 수행한다[12]. 순환 신경망의 순차적 계산 구조로 인한 학습 병목 현상을 해결하기 위해, RNN 없이 다중 CNN 모듈을 병렬로 구성하여 높은 성능을 달성한 연구도 있었다[13]. 또한, 실제 산업 현장에서 충분한 고장 데이터를 확보하기 어려운 한계를 극복하기 위해, 서로 다른 운용 조건의 데이터에서 학습한 지식을 전이학습을 통해 적용하여 예측 정확도를 높이는 연구도 제안되었다[14].

그러나 앞서 언급된 딥러닝 모델들은 대부분 내부 작동 원리를 파악하기 어려운 블랙박스 모델이라는 본질적 한계를 가진다[5]. 예측 결과의 근거를 이해할 수 없어 산업 현장에서의 신뢰도 확보에 어려움이 있었고, 이는 인공지능 모델의 실제 적용을 방해하는 주요한 제약으로 작용했다[15]. 이러한 배경에서 모델의 결정 과정을 투명하게 설명하는 설명가능한 인공지능의 필요성이 대두되었다[16]. 설명가능한 인공지능은 크게 블랙박스 모델의 예측 결과를 사후적으로 해석하는 Post-hoc 방식(LIME, SHAP)과 모델 자체가 투명한 구조를 가져 해석이 용이한 Ante-hoc 방식으로 나뉜다[17].

Ante-hoc 방식의 대표적인 모델인 EBM 모델은 블랙박스 모델과 유사한 수준의 예측 성능을 유지하면서도, 각 변수가 예측에 미치는 영향을 명확하게 설명하는 것을 목표로 한다[18]. 실제로 한 연구에서는 EBM 모델이 ANN 대비 결정계수에서 약 2% 낮은 성능을 보였지만, 별도의 특징 선택 없이도 핵심 변수를 자동 판별하는 효율성을 입증했다[18]. 또한, EBM 모델이 제공하는 설명은 실제 전문가의 분석과 높은 상관관계를 보여 모델의 신뢰성을 뒷받침한다[15].

본 연구에서는 이러한 EBM 모델의 장점을 잔여 수명 예측 문제에 도입하여, 설명 가능성에 기반한 변수 선택과 시계열 예측을 결합한 새로운 하이브리드 방법론을 제안하고자 한다.

Ⅲ. 변수 선택과 잔여 수명 예측을 위한 하이브리드 방법론 개발

1. 데이터 전처리 및 차원 축소

항공기 터빈 엔진의 상태 기반 정비를 위해서는 다중 센서로부터 수집된 시계열 데이터를 효과적으로 처리하는 것이 필수적이다. 항공기 터빈 엔진의 남은 수명을 정확히 예측하기 위해, 원본 데이터에 대한 정제 및 가공 과정이 선행되어야 하며, 전처리 과정은 다음과 같이 진행된다.

가. 잔여 수명 계산 및 상한 설정 (Clipping)

각 항공기 터빈 엔진의 잔여 수명은 최종 고장 시점을 기준으로 남은 작동 사이클을 역산하여 선형적으로 감소하는 값으로 정의된다. 그러나 실제 항공기 터빈 엔진은 수명 초기 단계에서 성능 저하가 거의 관찰되지 않아 센서 데이터의 변화가 거의 없는 안정 상태 구간을 보인다. 이 구간에서 잔여 수명만 선형으로 계속 감소하는 데이터를 모델에 그대로 학습시킬 경우, 모델은 센서 값의 변화와 잔여 수명 감소 간의 유의미한 상관관계를 찾지 못하고, 노이즈나 잘못된 패턴을 학습하여 예측 성능이 저하될 위험이 존재한다. 이러한 문제점을 해결하고 실제 부품의 열화 과정과 관련이 있는 데이터 패턴에 모델이 집중하도록 하기 위해, 아래 Fig. 1과 같이 잔여 수명 값에 최댓값을 설정하는 상한 설정 기법을 적용하였다.

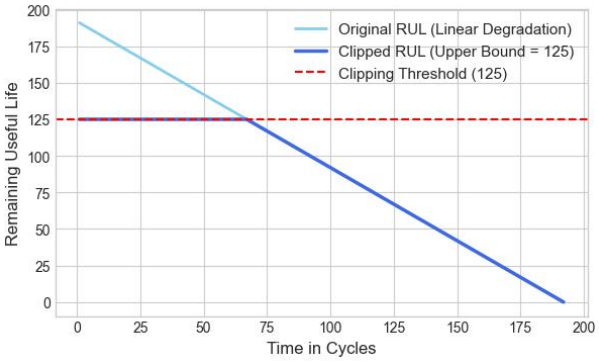

그림 1. 잔여 수명 상한 설정
Fig. 1. Upper limit of remaining useful life.

이를 통해 모델이 초기 안정 상태가 아닌, 실제 성능 저하가 발생하는 구간의 데이터 특성을 학습하도록 하였다.

나. 데이터 정규화 (Normalization)

데이터 정규화는 특정 변수의 영향력이 과도해지는 것을 방지하고 모델이 안정적으로 최적해를 찾을 수 있는 기반을 마련한다. Min-Max 스케일링의 수식은 (1)과 같다.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{1}$$

여기서 x는 원본 데이터, $x_{\min}$과 $x_{\max}$는 각각 해당 센서 데이터의 최솟값과 최댓값을 의미한다. x'는 정규화된 결과이다.

각 센서는 고유의 측정 단위와 값의 범위를 가지므로, 특정 변수의 영향력이 과도해지는 것을 방지하고 모델이 안정적으로 학습하기 위해 데이터 정규화 과정이 필수적이다. Fig. 2는 Unit 1의 센서 7과 12를 예시로 Min-Max 정규화의 적용 효과를 보여준다.

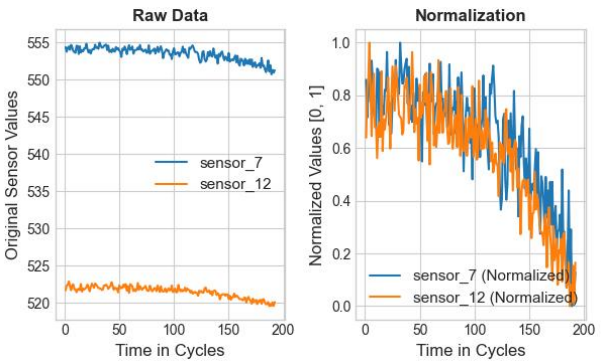

그림 2. Min-Max 정규화 적용 전후의 센서 데이터 변화 (엔진 1번)
Fig. 2. Sensor Data Before and After Min-Max Normalization (Unit 1).

정규화 이전에는 두 센서가 서로 다른 값의 범위를 나타내지만, 정규화 이후에는 두 센서 모두 [0, 1]의 동일한 범위로 조정되었음을 확인할 수 있다. 이러한 과정은 데이터의 고유한 추세는 유지하면서도, 범위 차이로 인한 모델의 학습 왜곡을 효과적으로 방지한다.

이를 위해, Min-Max 스케일링을 각 항공기 터빈 엔진 단위에 대해 개별적으로 적용하여 모든 센서 데이터의 범위를 0과 1 사이로 변환한다.

다. 차원 축소 (Dimension Reduction)

전처리 이후에도 데이터는 다수의 센서 변수를 포함하는 고차원 데이터 형태를 유지하며, 차원의 저주 문제를 초래하여 모델의 과적합이 발생하며 예측 성능이 저하될 수 있다. 따라서 본 연구에서는 모델의 성능과 효율성을 동시에 향상하기 위해 차원 축소 기법을 적용한다[19].

아래 Fig. 3과 같이 차원 축소는 크게 변수 추출(Feature Extraction)과 변수 선택(Feature Selection)으로 구분된다.

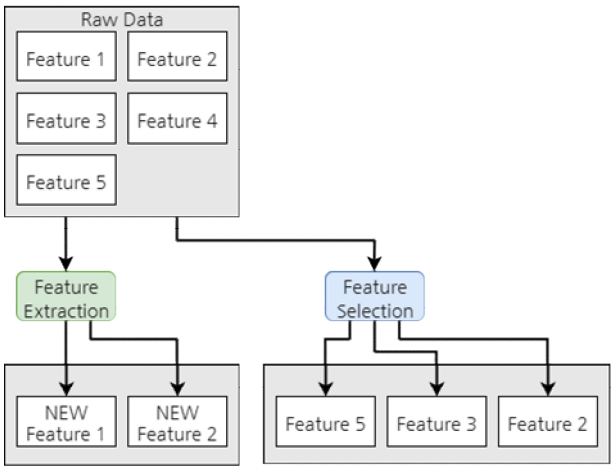

그림 3. 차원 축소 기법 중 변수 추출과 변수 선택의 비교
Fig. 3. Comparison of feature extraction and feature selection among dimension reduction techniques.

변수 추출은 기존 변수들을 조합하여 새로운 저차원의 변수를 생성하는 기법으로, 대표적으로 Fig. 4과 같이 주성분 분석(Principal Component Analysis, PCA)이 있다.

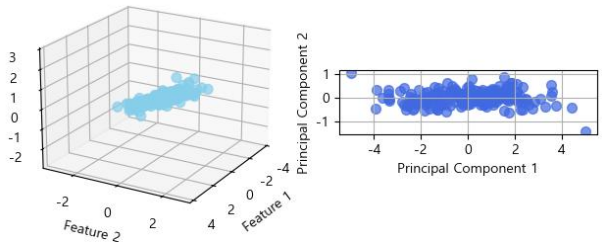

그림 4. 주성분 분석을 이용한 차원 축소 결과 시각화
Fig. 4. Visualization of Dimensionality Reduction using PCA.

주성분 분석은 고차원의 데이터를 저차원 공간으로 변환하여 정보 손실을 최소화하면서 데이터에 내재된 핵심 패턴을 파악하게 하는 차원 축소 기법이다[20].

이 과정에서 기존 변수들의 분산을 최대한 보존하는 새로운 축(주성분)이 생성되며, 이 주성분들은 서로 독립적이므로 변수 간 상관관계를 효과적으로 제거한다.

이와 같은 변수 추출 방식은 기존 변수들의 복잡한 상호작용을 통합하여 새로운 특징을 생성할 수 있는 반면 새롭게 만들어진 변수가 갖는 물리적 의미를 직관적으로 해석하기 어렵다는 한계가 존재한다[21].

변수 선택은 원본 데이터의 변수를 그대로 사용하여 예측 근거의 설명력을 높일수 있는 방법으로 잔여 수명 예측에 가장 중요한 영향을 미치는 변수들의 부분집합을 선택하는 기법이다[22]. 모델 학습 전, 통계적 특성을 이용하는 필터기법(Filter), 특정 모델의 예측 성능으로 변수 조합을 직접 평가하는 래퍼기법(Wrapper) 그리고 모델 학습 과정에서 변수 중요도를 함께 평가하는 임베디드(Embedded) 기법으로 구분된다.

본 연구에서는 변수 추출 방식이 갖는 한계를 극복하고 원본 센서의 물리적 의미를 보존하기 위해, 모델 학습 과정에서 변수 선택이 함께 이루어지는 임베디드 기법을 채택한다. 이를 위해, 설명가능한 인공지능 모델인 EBM 모델을 활용하여 잔여 수명 예측에 영향을 미치는 변수만을 선별하며, 최종 선택된 변수들은 제안하는 하이브리드 모델의 입력으로 사용된다.

2. 설명가능한 하이브리드 예측 모델 구축

본 연구에서는 항공기 터빈 엔진의 센서별 중요도와 복잡한 시계열 특성을 모두 반영하고자, 설명력이 뛰어난 EBM 모델과 시간적 패턴 학습에 강점이 있는 LSTM 모델을 결합한 하이브리드 모델을 제안한다.

가. EBM(Explainable Boosting Machine)

EBM 모델은 일반화 가법 모델(Generalized Additive Model, GAM)에 부스팅(Boosting) 기법을 결합한 글래스박스(Glass-box) 모델이다. 기존 GAM이 단일 함수 형태로 각 변수의 효과를 모델링하는 것과 달리, EBM 모델은 부스팅을 통해 각 변수에 대한 독립적인 형태 함수(shape function)를 반복적으로 학습하며, 필요에 따라 변수 간 교호작용도 모델에 포함할 수 있다. EBM 모델의 일반적인 수식은 (2)와 같다.

$$g(E(y)) = \beta_0 + \sum(f_j(x_j)) + \sum(f_{ij}(x_i, x_j)) \quad (2)$$

위 수식에서 $g(E(y))$는 예측하고자 하는 목표값, 즉 항공기 터빈 엔진의 RUL의 기댓값에 해당한다. 각 구성 요소는 다음과 같은 구체적인 의미를 가진다. $f_j(x_j)$은 개별 센서 변수(x_j)가 RUL 예측에 미치는 영향을 나타내는 형태 함수이며, 본 연구에서 사용된 데이터에서는 C-MAPSS 데이터셋의 특정 센서 측정값에 해당한다. EBM 모델은 학습을 통해 센서 값의 변화가 RUL 예측치를 어떤 형태로 변화시키는지를 f_j 함수로 도출한다. 다음 $f_{ij}(x_i, x_j)$은 두 센서 변수간의 교호작용이 RUL에 미치는 복합적인 영향을 모델링한다. 각 센서가 개별적으로 미치는 영향뿐만 아니라 변수 간 상호작용을 통해 복합적인 관계를 규명할 수 있는 장점이 있다. 또한, 모델 자체가 설명력을 내재한다는 것이 가장 큰 특징이다. 학습 과정에서 도출되는 변수별 형태 함수는 각 센서 값의 변화가 잔여 수명 예측에 미치는 영향을 시각화하여, 결과에 대한 직관적인 해석을 가능하게 한다.

또한, EBM 모델은 각 변수가 전체 예측 성능에 기여하는 정도를 나타내는 전역적 중요도를 정량적으로 제공한다. 이 중요도 점수를 기준으로 변수들의 순위를 선정하고 기여도가 낮은 변수들을 제거하는 방식으로 변수 선택을 수행한다. 이를 통해 모델의 복잡도를 낮추고 과적합을 방지하며, 기존 부스팅 모델의 높은 예측 성능을 유지할 수 있다. 이렇게 EBM을 통해 선별된 핵심 변수들은 후속 시계열 예측 모델의 입력으로 사용된다. EBM 모델은 Microsoft의 InterpretML 프레임워크를 통해 구현 가능하다[23].

나. LSTM(Long Short Term Memory)

LSTM 모델은 순환 신경망(RNN)의 한 종류로, 시계열 데이터 내 장기 의존성(long-term dependency) 문제를 해결하기 위해 설계된 구조이다. RNN 모델은 순환 구조를 통해 이전 시점의 정보를 현재로 전달하지만, 시퀀스가 길어질수록 기울기 소실 문제가 발생하여 과거의 중요한 정보가 소실되는 한계를 가진다. LSTM 모델은 이러한 문제를 해결하기 위해 셀 상태(Cell State)와 여러 게이트(Gate)로 구성된 정교한 내부 구조를 도입하였으며, 그 전체 구조는 Fig. 5와 같다.

LSTM의 핵심은 정보가 시퀀스 전체를 관통하여 흐르는 셀 상태와, 이 정보의 흐름을 제어하는 세 개의

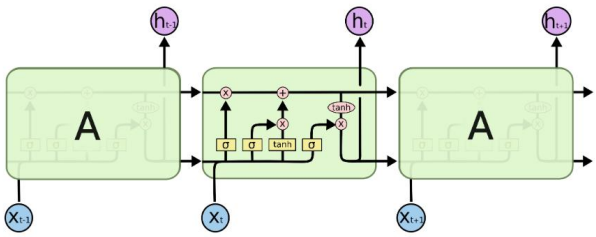

그림 5. LSTM 의 구조도
Fig. 5. Architecture of a Long Short-Term Memory

게이트(삭제, 입력, 출력)에 있다. 삭제 게이트(Forget Gate)는 이전 셀 상태에서 불필요한 정보를 선택적으로 제거하는 역할을 한다. 이후 입력 게이트(Input Gate)는 현재 시점의 입력으로부터 의미 있는 정보를 선별하여 셀 상태에 추가할 새로운 정보를 결정한다. 이렇게 갱신된 현재 시점의 셀 상태는 다음 시점으로 전달되어 장기적인 정보 흐름을 유지하게 된다. 마지막으로 출력 게이트(Output Gate)는 갱신된 셀 상태를 기반으로 현재 시점의 은닉 상태를 결정하여 외부로 출력한다.

이러한 게이트 메커니즘을 통해 LSTM 모델은 시계열 데이터의 시간적 흐름 속에서 중요한 정보를 장기간 소실 없이 유지하*며 학습할 수 있는 특성을 가진다. 따라서 항공기 터빈 엔진의 센서 데이터처럼 시간에 따라 동적으로 변화하는 열화 과정을 모델링하는 데 효과적이며, 실제로 잔여 수명 예측 문제에 널리 활용되고 있다[24]. 즉, 특정 시점의 데이터뿐만 아니라 과거의 운용 이력 전체를 종합적으로 고려하여 잔여 수명을 예측하는 역할을 담당한다.

최종 잔여 수명은 EBM 모델으로 선별한 핵심 변수를 LSTM 모델의 입력으로 사용하여 예측한다. 이 하이브리드 방식은 각 모델의 장점을 결합함으로써, 단일 모델보다 안정적이고 정확한 예측 성능을 보여준다.

3. 항공기 터빈 엔진 잔여 수명 예측 및 평가 프로세스

본 연구에서 제안하는 하이브리드 모델 기반의 잔여 수명 예측 및 평가 프로세스는 아래 Fig. 6과 같이 나타난다.

원본 데이터로부터 모델 학습에 적합한 데이터를 가공하기 위해, 각 항공기 터빈 엔진의 마지막 운용 사이클을 고장 시점으로 정의하여 잔여 수명을 선형적으로 계산하고 그 최댓값을 특정 값으로 제한한다. 이는 모델이 실제 고장과 관련된 유의미한 열화 구간에 집중하여 학습하도록 유도하는 역할을 한다[25]. 이후 각 센서의 고유한 단위와 값의 범위를 통일하기 위해 Min-Max 스케일링을 항공기 터빈 유닛별로 적용하여 모든 센서 값을 0과 1 사이로 정규화한다.

전처리가 완료된 데이터는 모델의 일반화 성능을 측정하기 위해 학습 데이터와 테스트 데이터로 분할된다. 이때, 일반적인 랜덤 분할 방식이 아닌 항공기 터빈 엔진 단위를 기준으로 학습 데이터(엔진 1~80)와 테스트 데이터(엔진 81~100)를 분리한다. 데이터를 무작위로 분할할 경우, 동일한 엔진의 운행 데이터가 학습 데이터와 시험 데이터에 모두 포함될 수 있다. 이러한 데이터 중복은 모델이 학습 시 이미 접한 패턴으로 예측하게 만들어, 결과적으로 일반화 성능을 과대평가하는 오류를 불러온다. 따라서 모델이 학습 과정에서 보지 못한 새로운 엔진에 대한 예측 성능을 신뢰성 있게 평가하기 위해서는 엔진 단위의 데이터 분할이 필수적이다.

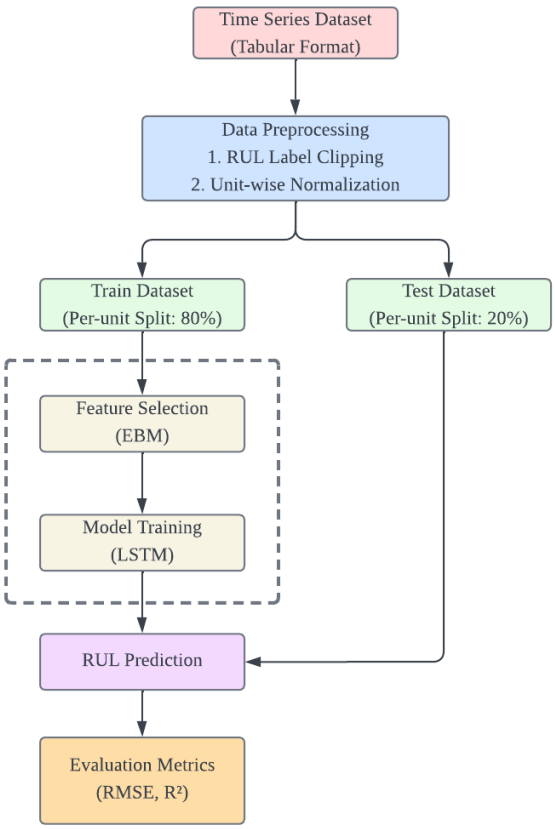

그림 6. EBM-LSTM 기반 잔여 수명 예측 모델의 학습 및 평가 프로세스

Fig. 6. Training and Evaluation Process of the EBM-LSTM based RUL Prediction Model.

이를 통해 분할된 학습 데이터는 EBM-LSTM 하이브리드 모델의 각 구성 요소에 맞게 두 가지 형태로 재구성된다. EBM 모델이 변수와 잔여 수명 간의 관계를 학습하고 변수 중요도를 도출하기 위한 테이블 형태의 데이터이며, 다른 하나는 LSTM 모델이 시간의 흐름에 따른 동적 열화 패턴을 학습하기 위한 시계열 시퀀스 데이터이다. 이처럼 각기 다른 형태의 데이터를 활용함으로써, 제안하는 모델은 변수별 영향력과 시간적 종속성을 동시에 모델링하며, 최종적으로 학습된 모델을 사용하여 테스트 데이터셋의 잔여 수명을 예측한다. 최종 예측값은 실제 잔여 수명과의 비교를 통해 결정계수(R^2) 및 평균 제곱근 오차(RMSE) 같은 정량적 지표로 정확도를 평가한다. 결정계수(R^2) 및 평균 제곱근 오차(RMSE) 수식은 각각 (3), (4)와 같다.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y_i})^2}{\sum_{i=1}^{n}(y_i - \overline{y})^2} \quad (3)$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2} \quad (4)$$

식 (3)에서 y_i는 i번째 테스트 데이터의 실제 잔여 수명(Actual RUL)을, $\hat{y_i}$ 는 제안 모델이 예측한 잔여 수명(Predicted RUL)을, 그리고 $\overline{y_i}$ 는 전체 테스트 데이터의 실제 잔여 수명 평균(Mean of Actual RUL)을 의미한다. R^2 값은 1에 가까울수록 모델이 실제 엔진의 열화 패턴을 정확하게 추종하여 설명력이 높음을 나타내며, 이는 상태 기반 정비 관점에서 모델 예측 결과의 신뢰도를 판단하는 중요한 근거가 된다. 식 (4)는 실제 잔여 수명과 모델의 예측값 간의 차이, 즉 오차의 크기를 나타낸다. 예측 오차의 크기를 실제 목표 변수와 동일한 단위로 표현하므로, 모델의 정밀도를 직관적으로 파악할 수 있게 한다. 낮은 RMSE 값은 더 정밀하고 신뢰성 높은 잔여 수명 예측 성능을 의미한다. 이를 위해 EBM 모델이 제공하는 변수별 중요도와 형태 함수를 시각적으로 분석하여, 예측 결과가 높은 정확도뿐만 아니라 논리적 타당성과 신뢰성을 갖추었는지 확인하였다.

Ⅳ. 실 험

1. 잔여 수명 예측을 위한 항공기 터빈 엔진 데이터

본 연구에서는 항공기 터빈 엔진의 상태를 예측하고 잔여 수명을 진단하기 위해 NASA에서 제공하는 C-MAPSS (Commercial Modular Aero-Propulsion System Simulation) 데이터셋을 활용하였다. 데이터셋은 다양한 작동 조건과 초기 마모 상태에서 시뮬레이션된 고차원 시계열 데이터로 구성되어 있다[26].

제안하는 하이브리드 모델의 예측 성능을 검증하기 위해, 단일 운용 조건과 단일 고장 유형를 가진 C-MAPSS 데이터셋의 FD001을 대상 데이터로 선정하였다. 해당 데이터의 상세 구성은 아래 Table 1에 정리되어 있다[24].

Table 1은 FD001 데이터셋에 포함된 21개 센서의 물리적 의미와 단위, 그리고 시간에 따른 일반적인 변화 경향을 정리한 것이다. 각 센서는 터보팬 엔진의 주요 구성 요소에서 측정된 온도, 압력, 속도 등의 물리량을 나타내며, 각 센서 데이터의 추세는 잔여 수명 감소에 따라 함께 증가 또는 감소하는 동적 패턴, 운용 시간 동안 거의 일정한 값을 유지하는 정적 패턴으로 구분되었다. 이 중 잔여 수명과의 상관관계가 없어 모델 학습에 유의미한 정보를 제공하지 않는 정적 센서들은 불필요한 노이즈로 작용하거나 계산 복잡도를 가중시킬 수 있다. 따라서 전체 21개 센서 중 이러한 7개의 정적 변수를 분석에서 제외하고, 최종적으로 14개의 유효한 동적 변수만을 채택하여 모델의 학습 효율성을 높이고 과적합을 방지하고자 하였다.

표 1. 항공기 터빈 엔진의 센서 데이터 목록 및 설명
Table 1. List and Description of Sensor Parameters.

Sensor	Parameter	Description with units	Trend
1	T2	Total Temperature in fan inlet (oR)	~
2	T24	Total Temperature at LPC outlet (oR)	I
3	T30	Total Temperature at HPC outlet (oR)	I
4	T50	Total Temperature at LPT outlet (oR)	I
5	P2	Pressure at fan inlet (psia)	~
6	P15	Total pressure in bypass-duct (psia)	~
7	P30	Total pressure at HPC outlet (psia)	D
8	Nf	Physical fan speed (rpm)	I
9	Nc	Physical core speed (rpm)	I
10	Epr	Engine pressure ratio (-)	~
11	Ps30	Static pressure at HPC outlet (psia)	I
12	Phi	Ratio of fuel flow to Ps30 (psi)	D
13	NRf	Corrected fan speed (rpm)	I
14	Nrc	Corrected core speed (rpm)	D
15	BPR	Bypass ratio (-)	I
16	farB	Burner fuel air ratio (-)	~
17	htBleed	Bleed enthalpy (-)	I
18	NF-dmd	Demanded fan speed (rpm)	~
19	PCNR-dmd	Demanded corrected fan speed (rpm)	~
20	W31	HPT coolant bleed (lbm/s)	D
21	W31	LPT coolant bleed (lbm/s)	D

항공기 터빈 엔진의 초기 운용 구간에서 발생할 수 있는 불필요한 계산을 방지하기 위해, 잔여 수명의 최댓값을 125로 제한하였다. 이와 같은 설정은 모델이 실제 열화가 진행되는 구간에 집중하여 학습할 수 있도록, 기존 연구를 기반으로 결정하였다[27, 28].

2. 실험 분석 및 결과

변수 선택에 앞서, 잔여 수명 예측에 적합한 기반 모델을 선정하기 위해 널리 사용되는 트리 기반 앙상블 모델인 Gradient Boosting, LightGBM, Extra Trees를 포함하여 성능을 사전 평가하였으며, 모델의 성능을

종합적으로 평가하기 위해 설명력을 나타내는 R^2와 예측 오차를 나타내는 RMSE를 평가 지표로 활용하였다. 이에 따른 모델별 예측 성능 비교 결과는 Table 2와 같이 제시하였다.

표 2. 모델별 예측 성능 비교
Table 2. Predictive Performance Comparison by Model.

모델	RMSE	R^2
Gradient Boosting	41.78	0.62
LightGBM	42.14	0.61
Extra Trees	42.82	0.6
MLP[29]	37.56	-
RVR[29]	23.80	-
SVR[29]	20.96	-
CNN[29]	18.45	-
EBM	16.83	0.834
2D-CNN+LSTM[30]	16.13	-
CNN+GRU[31]	16.29	-
LSTM	15.19	0.865
Proposed Method (EBM-LSTM)	15.33	0.862

성능 평가 결과, 본 연구에서 제안하는 EBM-LSTM 모델은 비교 모델 대비 설명 가능성과 예측 성능을 동시에 향상시키는 우수성을 입증하였다.

또한, EBM 모델은 예측 성능과 설명 가능성 간의 Trade-off를 극복한 모델로서 각 변수가 예측에 미치는 영향을 명확하게 파악할 수 있는 장점을 가진다. 본 연구에서는 이러한 EBM 모델의 특성을 활용하여, 모델이 제공하는 전역적 중요도를 기반으로 고차원의 센서 데이터로부터 잔여 수명 예측에 핵심적인 변수를 선별하였다. 학습 데이터를 EBM 모델에 적용하여 각 변수의 기여도를 정량적으로 산출하였으며, 그 결과를 Fig. 7과 같이 중요도 점수가 높은 순으로 정렬하여 제시하였다.

본 연구에서는 예측 정확도를 유지하면서 모델의 연산 효율을 높이고 과적합을 방지하기 위해, EBM의 변수 중요도를 기반으로 최적의 입력 변수 집합을 선정하였다. 이를 위해 EBM이 산출한 중요도 순위에 따라 기여도가 가장 낮은 변수부터 순차적으로 제거하며 각 단계에서의 예측 성능 변화를 관찰하였다.

Fig. 8은 변수 제거에 따른 성능 변화를 보여준다. 전체 변수 중 중요도가 낮은 변수를 순차적으로 제거해도 상위 8개 변수가 남을 때까지 성능 저하는 미미했으나, 8개 미만으로 변수가 줄어들자 RMSE가 급격히 증가하는 변곡점이 관찰되었다.

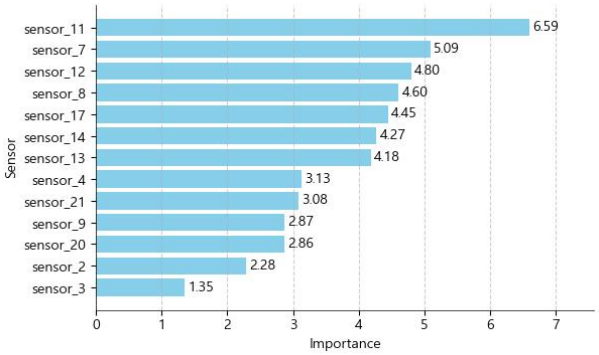

그림 7. 전역적 변수 중요도 기반 센서 변수별 예측 기여도 순위
Fig. 7. Ranking of Sensor Variables by Predictive Contribution based on Global Importance.

이는 상위 8개 변수가 잔여 수명 예측에 필요한 핵심 정보를 대부분 포함하고 있으며, 그 외 변수들은 예측 성능에 미치는 기여도가 낮거나 오히려 노이즈로 작용할 가능성이 있다. 따라서 본 연구에서는 모델의 복잡도를 낮춰 연산 효율성을 확보하고 예측 성능의 손실을 최소화하는 최적점을 8개로 판단하여, 하이브리드 모델의 입력으로 구성하였다.

축소된 변수 집합을 각 모델에 동일하게 적용하여 성능을 정량적으로 비교 및 평가하였다.

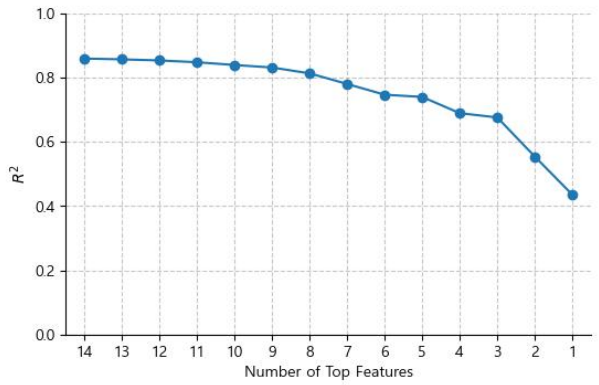

그림 8. 입력 변수 개수에 따른 모델 예측 성능 변화
Fig. 8. Changes in model prediction performance according to the number of input features.

Table 3에 나타난 바와 같이 분석 결과, 제안하는 EBM-LSTM 하이브리드 모델은 입력 변수를 14개에서 8개로 축소했음에도 R^2가 0.862에서 0.861로 성능 저하가 거의 발생하지 않았다. 이는 EBM 모델의 설명 가능성을 활용한 변수 선택이 예측에 필수적인 핵심 변수

표 3. 변수 선택 전후의 잔여 수명 예측 모델 별 성능 비교
Table 3. Comparison of Model Performance for RUL Prediction Before and After Feature Selection.

	8 Sensors	
	RMSE	R^2
EBM	15.56	0.858
LSTM	18.69	0.795
Proposed Method (Top 8 Sensor)	15.40	0.861
Proposed Method (Bottom 8 Sensor)	26.33	0.593

만을 체계적으로 선별함으로써, 모델의 효율성은 높이면서도 성능 손실을 최소화했음을 나타낸다. 또한, 제안된 변수 선택 방식의 유효성을 검증하기 위해 중요도 하위 8개 변수를 동일한 하이브리드 모델에 적용한 결과, RMSE는 26.34, R^2는 0.593으로 성능이 크게 저하됨을 확인하였다. 이는 상위 변수를 사용했을 때의 R^2 값 0.861과 비교하면 현저히 낮은 수치로, EBM 모델이 예측에 기여도가 낮은 변수들을 효과적으로 식별했음을 나타낸다.

반면, 단일 모델들은 변수 선택에 따라 상이한 결과를 보였다. LSTM 단일 모델의 경우, 변수 축소 후 R^2가 0.865에서 0.795로 상대적으로 뚜렷하게 감소하여 성능 저하가 명확히 나타났다. 이는 시계열 패턴 학습에 의존하는 LSTM 모델이 EBM 모델과 같은 사전 변수 중요도 분석 없이 입력 변수가 축소될 경우, 예측에 필요한 주요 정보를 잃어 성능이 저하될 수 있음을 의미한다.

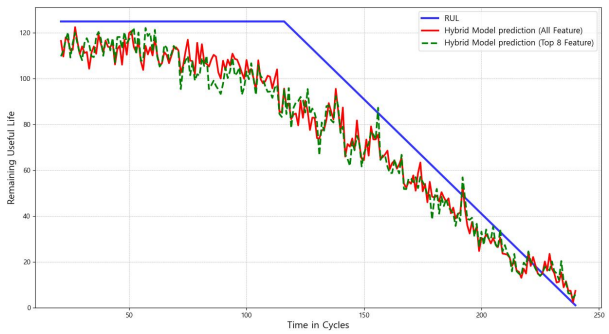

그림 9. 엔진 #81의 실제 RUL과 예측 RUL 비교
Fig. 9. Comparison of Predicted and Actual RUL for Engine #81.

또한, Fig. 9는 제안하는 하이브리드 모델의 예측 결과를 단일 엔진(#81)에 대해 나타낸 그래프이다. 전체 변수를 사용한 예측과 상위 8개 변수만을 사용한 예측 결과는 실제 수명 값과 매우 유사한 궤적을 보이며 거의 일치하는 것을 보여준다. 이는 EBM 모델기반의 변수 선택이 성능 저하 없이 모델의 복잡도를 효과적으로 낮추었음을 나타낸다.

결론적으로, 제안하는 EBM-LSTM 하이브리드 모델은 EBM 모델의 설명 가능성에 기반한 변수 선택이 단순히 모델을 간소화하는 것을 넘어, LSTM 모델과 같은 시계열 모델의 예측 안정성을 확보할 수 있다.

V. 결 론

본 연구에서는 항공기 터빈 엔진의 잔여 수명 예측에서 높은 정확도와 함께 모델의 예측 근거를 명확히 설명할 수 있는 설명 가능성을 동시에 확보하는 것을 목표로 하였다. 기존 딥러닝 모델들이 가지는 블랙박스 문제를 해결하기 위해, 설명가능한 인공지능 방법론을 잔여 수명 예측 프레임워크에 도입하였다. 이를 위해, 모델 자체가 우수한 설명력을 제공하는 EBM을 활용하여 잔여 수명 예측에 영향을 미치는 핵심 변수를 체계적으로 선별하고, 이를 시계열 예측에 특화된 LSTM 모델과 결합하는 하이브리드 방법론을 제안하였다.

C-MAPSS 데이터셋을 활용한 실험 결과, 제안하는 EBM-LSTM 하이브리드 모델은 잔여 수명 예측에서 높은 성능을 보였다. 특히 EBM 모델의 전역적 변수 중요도 분석을 통해, 전체 14개의 센서 중 상위 8개의 핵심 변수만으로도 모든 변수를 사용했을 때와 대등한 수준의 예측 성능을 입증하였다. 이는 제안된 방법론이 불필요한 변수를 제거하여 모델의 복잡도를 낮추고 연산 효율성을 개선하면서도, 예측 성능의 손실은 최소화할 수 있음을 보여준다.

그러나 단일 운용 조건 및 고장 모드를 가진 FD001 데이터셋에 한정하여 검증을 수행하였다는 점에서 한계가 존재한다. 향후 연구에서는 다양한 운용 조건과 복합적인 고장 모드를 포함하는 FD002, FD004 등의 데이터셋에 제안 방법론을 적용하여 모델의 일반화 성능과 강건성을 추가적으로 검증할 필요가 있다. 또한, EBM 모델의 변수 선택 기능과 LSTM 모델의 예측 기능을 순차적으로 활용하였으나, 두 모델을 더욱 유기적으로 통합하는 새로운 하이브리드 아키텍처 개발에 대한 후속 연구가 필요하다.

본 연구에서 제안된 방법론은 예측 성능 향상과 더불어 특정 센서의 중요성에 대한 근거를 제공하여, 현장 엔

지니어는 제안된 방법론을 통해 예측 결과에 대한 신뢰를 확보하고, 이를 기반으로 효과적인 유지보수 의사결정을 내릴 수 있다. 특히, 고신뢰성이 요구되는 산업 현장에서 인공지능 기반 예지보전 시스템의 적용 가능성을 제고하는 데 기여할 것으로 기대된다.

REFERENCES

[1] M. Baek, H. Kim, J. Ban, and K. Koo, “Development of 2D CNN-based model for remaining useful life of turbofan engine,” in *Proc. Fall Conf. of the Institute of Electronics and Information Engineers (IEIE)*, pp. 261-263, Nov. 2023.

[2] D. Kim, T. Kim, and D. Shin, “Remaining useful life estimation method for lithium-ion batteries based on history of battery usage data using deep learning,” in *Proc. Spring Conf. of the Korean Institute of Electrical Engineers (KIEE)*, pp. 134-135, May 2023.

[3] F. Cheng, L. Qu, and W. Qiao, “Fault prognosis and remaining useful life prediction of wind turbine gearboxes using current signal analysis,” *IEEE Transactions on Sustainable Energy*, vol. 9, no. 1, pp. 157-167, Jan. 2018.

[4] H. Jeong and E.-S. Jung, “Comparative Study on the Short-term Forecasting Performance of LLM Models for Time Series Data,” *Journal of The Institute of Electronics and Information Engineers*, vol. 62, no. 6, pp. 29-37, Jun. 2025.

[5] M. L. Baptista, M. Mishra, E. M. Henriques, and H. Prendinger, “Using explainable artificial intelligence to interpret remaining useful life estimation with gated recurrent unit,” *Proc. Annu. Conf. of the Prognostics and Health Management Society*, pp. 1-16, Oct. 2024.

[6] J. Lee, Y.-I. Park, M. Cho, and S.-J. Kang, “Explainable Graph Neural Network-based Time Series Anomaly Detection,” *Journal of The Institute of Electronics and Information Engineers* vol. 62, no. 1, pp. 83-90, Jan. 2025.

[7] ISO/IEC TR 24028:2020, "Information technology — Artificial intelligence — Overview of trustworthiness in artificial intelligence,"

[8] Y. Choo and S. Shin, "Cost-optimal preventive maintenance based on remaining useful life prediction and minimum-repair block replacement models," *Journal of the Korean Institute of Industrial Engineers*, vol. 45, no. 3, pp. 18-30, Sep. 2022.

[9] A. Fajar, S. Yazid, and I. Budi, "Enhancing Phishing Detection through Feature Importance Analysis and Explainable AI: A Comparative Study of CatBoost, XGBoost, and EBM Models," *arXiv preprint* arXiv:2411.06860, 2024.

[10] J. M. Kim, H. W. Kang, Y. Cho, K. H. Kwon, A. S. Yeon, and H. Kim, “Prediction remaining useful life of aircraft turbofans using transfer learning based CNN-LSTM,” *Korean Transactions on Software and Data Engineering (KTSDE)*, vol. 13, no. 12, pp. 700-709, Dec. 2024.

[11] A. F. Azyus, S. K. Wijaya, and B. Kurniawan, "Remaining Useful Life Prediction of Turbofan Engines Using CNN-GRU: A Comparative Study on C-MAPSS Dataset," *Journal of Mechanical, Civil and Industrial Engineering*, vol. 6, no. 1, pp. 19-27, Feb. 2025.

[12] E. Zio, “Prognostics and Health Management (PHM): Where are we and where do we (need to) go in theory and practice,” *Reliability Engineering & System Safety*, vol. 218, p. 108119, Apr. 2022.

[13] H. Kim, D. Kim, J. Ban, and K. Koo, “CMAPSS Data Remaining Validity Prediction Using Deep Learning-Based Models with Parallel Connectivity Configuration,” in *Proc. of KIIT Conference*, pp. 199-203, Nov. 2024.

[14] J. Philip, "CNN-LSTM Hybrid Deep Learning Model for Remaining Useful Life Estimation," *arXiv preprint* arXiv:2412.15998, 2024.

[15] S. M. Farea, M. E. Mumcuoglu, and M. Unel, "An Explainable AI approach for detecting failures in air pressure systems," *Engineering Failure Analysis*, vol. 173, p. 109441, 2025.

[16] A. Zentner, "From Opacity to Transparency: Advancing Explainable AI Through Black-Box, White-Box, and Glass-Box Models," *SSRN Electronic Journal*, May 2025.

[17] R. Guidotti, A. Monreale, S. Ruggieri, F. Turini, F. Giannotti, and D. Pedreschi, "A survey of methods for explaining black box

models," *ACM Computing Surveys (CSUR)*, vol. 51, no. 5, pp. 1-42, Aug. 2018.

[18] L. Colantonio, et al., "Explainable AI for tool condition monitoring using Explainable Boosting Machine," *Procedia CIRP*, vol. 133, pp. 138-143, 2025.

[19] S. Kumar, A. Gaurav, A. Tiwari, S. Verma, and S. Ghosh, "Feature dimensionality reduction: A review," *Complex & Intelligent Systems*, vol. 8, no. 5, pp. 3207-3234, Oct. 2022.

[20] Z. M. Radeef, S. H. Hashem, and E. K. Gbashi, "New Feature Selection Using Principal Component Analysis," *Journal of Soft Computing and Computer Applications*, vol. 1, no. 2, p. 4, 2024.

[21] I. T. Jolliffe and J. Cadima, "Principal component analysis: a review and recent developments," *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, p. 20150202, Apr. 2016.

[22] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," J*ournal of Machine Learning Research*, vol. 3, pp. 1157-1182, Mar. 2003.

[23] K. B. Donge, L. N. Yadav, and N. B. Jiwane, "InterpretML: A Unified Framework for Machine Learning Interpretability," *International Journal of Advanced Research in Computer and Communication Engineering*, vol. 12, no. 5, pp. 1397-1399, May 2023.

[24] J. Y. Lim, D. H. Kim, D. W. Noh, and B. G. Lee, "Remaining useful life prediction for lithium-ion batteries using EMD-CNN-LSTM hybrid method," *J. Power Electron.*, vol. 27, no. 1, pp. 48-55, Feb. 2022.

[25] X. Li, Q. Ding, and J.-Q. Sun, "Remaining useful life estimation in prognostics using deep convolution neural networks," *Reliability Engineering & System Safety*, vol. 172, pp. 1-11, Apr. 2018.

[26] O. Asif, et al., "A deep learning model for remaining useful life prediction of aircraft turbofan engine on C-MAPSS dataset," *IEEE Access*, vol. 10, pp. 95425-95440, 2022.

[27] C.-S. Hsu and J.-R. Jiang, "Remaining useful life estimation using long short-term memory deep learning," in *Proc. IEEE Int. Conf. Appl. Syst. Invention (ICASI)*, Chiba, Japan, Apr. 2018, pp. 58-61.

[28] Z. Zhao, B. Liang, X. Wang, and W. Lu, "Remaining useful life prediction of aircraft engine based on degradation pattern learning," *Reliab. Eng. Syst. Saf.,* vol. 164, pp. 74-83, Aug. 2017

[29] Babu, G.S.; Zhao, P.; Li, X. Deep convolutional neural network based regression approach for estimation of remaining useful life. In Proceedings of the International Conference on Database Systems for Advanced Applications, Dallas, TX, USA, 16-19 April 2016; pp. 214-228.

[30] Kong, Z., Cui, Y., Xia, Z., Lv, H., "Convolution and Long Short-Term Memory Hybrid Deep Neural Networks for Remaining Useful Life Prognostics". Applied Sciences, Oct. 2019.

[31] A. F. Azyus, S. Kusuma, and M. Naved, "Prediction of Remaining Useful Life Using the CNN-GRU Network: A Study on Maintenance Management," Software Impacts, Vol. 17, pp. 100535, 2023.

저 자 소 개

김 기 현(정회원)
2024년~현재, 한국산업기술시험원 산업인공지능혁신센터 연구원
2019년 동의대학교 메카트로닉스공학과 학사 졸업.
2024년 경기대학교 산업시스템공학과 석사 졸업.
<주관심분야 : 인공지능, 컴퓨터 비전, 데이터마이닝, 신뢰성분석>

김 주 현(비회원)
2025년~현재, 한국산업기술시험원 산업인공지능혁신센터 연구원
2021년 수원대학교 산업공학과 학사 졸업.
2025년 성균관대학교 산업공학과 석사 졸업.
<주관심분야 : 품질공학, 인공지능, 공정최적화, 컴퓨터 비전>

임 대 영(정회원)
2021년~현재, 한국산업기술시험원 산업인공지능혁신센터 선임연구원
2010년 전북대학교 전자공학과 학사 졸업.
2012년 전북대학교 전자공학과 석사 졸업.
2018년 전북대학교 전자공학과 박사 졸업.
<주관심분야 : 자동제어, 인공지능, 영상처리, 컴퓨터 비전>

권 종 원(정회원)
2013년~현재, 한국산업기술시험원 산업인공지능혁신센터 센터장/책임연구원
2005년 서울과학기술대학교 전자공학과 학사 졸업.
2008년 서울시립대학교 전자공학과 석사 졸업.
2012년 서울시립대학교 전자공학과 박사 졸업.
<주관심분야 : 빅데이터, 국제표준, IoT, 스마트제조>